Лекция 4

- Уровни компиляции *nvcc*.
- .cubin, .fatbin, .gpu и .ptx файлы.
- PTX (Parallel Thread eXecution) ISA (Instruction Set Architecture).

```
global void gTest0(float* a, float* b){
  int tid=threadIdx.x+blockIdx.x*blockDim.x;
  a[tid]=a[tid]+b[tid];
int main(){
  gTest0<<<N/128, 128>>>(a d,b d);
  cudaDeviceSynchronize();
```

```
tests/test0> nvcc -g -G test0m.cu -o test0m
/tests/test0> cuda-gdb test0m
```

```
(cuda-gdb) list gTest0
        #include <stdio.h>
        #include <malloc.h>
         global void gTest0(float* a, float* b) {
            int tid=threadIdx.x+blockIdx.x*blockDim.x;
            a[tid]=a[tid]+b[tid];
        int main(){
10
            int N=1024;
```

(cuda-gdb) **break 5**

```
(cuda-gdb) run

CUDA thread hit Breakpoint 1, gTest0<<<(8,1,1),(128,1,1)>>>
(a=0x7fffc3200000, b=0x7fffc3201000)
    at test0m.cu:5
    int tid=threadIdx.x+blockIdx.x*blockDim.x;
```

```
(cuda-gdb) disassemble
Dump of assembler code for function Z6gTest0PfS:
 0x00007fffc8e3f800 <+0>: MOV R1, c[0x0][0x28]
 0x00007fffc8e3f810 <+16>: MOV R2, RZ
 0x00007fffc8e3f820 <+32>: LDC.64 R2, c[0x0][R2+0x160]
 0x00007fffc8e3f830 <+48>: MOV R7, R2
 0x00007fffc8e3f840 <+64>: MOV R8, R3
 0x00007fffc8e3f850 <+80>: MOV R7, R7
 0x00007fffc8e3f860 <+96>: MOV R8. R8
0x00007fffc8e3f8e0 <+224>: MOV R8, R8
 0x00007fffc8e3f8f0 <+240>: MOV R5, R5
0x00007fffc8e3f900 <+256>: MOV R6, R6
=> 0x00007fffc8e3f910 <+272>: S2R R0, SR TID.X
 0x00007fffc8e3f920 <+288>: MOV R0, R0
 0x00007fffc8e3f930 <+304>: S2R R2, SR CTAID.X
0x00007fffc8e3f940 <+320>: MOV R2. R2
0x00007fffc8e3fca0 <+1184>: BRA 0x4a0
 0x00007fffc8e3fcb0 <+1200>: NOP
```

0x00007fffc8e3fcc0 <+1216>: NOP

Раздельная компиляция

```
extern "C"
__global___ void gTest2(float* a, float* b){
    int tid=threadIdx.x+blockIdx.x*blockDim.x;
    a[tid]=a[tid]+b[tid];
}

test2.cu
```

```
#include <stdio.h>
#include <malloc.h>
extern "C" __global__ void gTest2(float*, float*);
int main(){
    int N=1024;
    float* a=(float*)calloc(N, sizeof(float));
    float* b=(float*)calloc(N, sizeof(float));
    for(int i=0; i<N; i++){
    a[i]=2*i;
    b[i]=2*i+1;
```

test2m.cu

```
float *a_d, *b_d;
cudaMalloc((void**)&a d, N*sizeof(float));
cudaMalloc((void**)&b d, N*sizeof(float));
cudaMemcpy(a d, a, N*sizeof(float), cudaMemcpyHostToDevice);
cudaMemcpy(b d, b, N*sizeof(float), cudaMemcpyHostToDevice);
gTest2<<<N/128,128>>>(a d,b d);
cudaDeviceSynchronize();
cudaMemcpy(a, a d, N*sizeof(float), cudaMemcpyDeviceToHost);
for(int i=0; i<N; i+=N/16)
printf("%g\n",a[i]);
```

tests/test2> nvcc -c test2.cu tests/test2> nvcc -c test2m.cu tests/test2> nvcc test2.o test2m.o -o test2e

```
#include <stdio.h>
#include <malloc.h>
#include <cuda.h>
extern "C" void hLauncherTest2(float* a, float* b, int N);
int main(){
   hLauncherTest2(a_d,b_d,N);
```

```
global void gTest2(float* a, float* b){
    int tid=threadIdx.x+blockIdx.x*blockDim.x;
    a[tid]=a[tid]+b[tid];
extern "C"
void hLauncherTest2(float* a, float* b, int N){
gTest2<<<N/128,128>>>(a,b);
cudaDeviceSynchronize();
```

nvcc -Xcompiler -fPIC -shared test2.cu -o libtest2.so

export LD_LIBRARY_PATH=\$LD_LIBRARY_PATH:.

nvcc test2m.cu -L. -ltest2 -o test2m

PTX

PTX (Parallel Thread eXecution) определяет виртуальную машину и набор инструкций (ISA - Instruction Set Architecture). PTX программа транслируется во время загрузки в команды соответствующего GPU и машинный код загружается на GPU драйвером.

tests/test2> nvcc -ptx test2.cu

```
version 8.5
.target sm_52
.address size 64
    // .globl
               gTest2
.visible .entry gTest2(
    .param .u64 gTest2 param 0,
    .param .u64 gTest2 param 1
    .reg .f32
                %f<4>;
    .reg .b32
               %r<5>;
                %rd<8>;
    .reg .b64
```

test2.ptx

```
Id.param.u64 %rd1, [gTest2 param 0];
Id.param.u64 %rd2, [gTest2_param_1];
cvta.to.global.u64 %rd3, %rd2;
cvta.to.global.u64 %rd4, %rd1;
mov.u32 %r1, %tid.x;
mov.u32 %r2, %ctaid.x;
mov.u32 %r3, %ntid.x:
mad.lo.s32 %r4, %r2, %r3, %r1;
mul.wide.s32 %rd5, %r4, 4;
add.s64 %rd6. %rd4. %rd5:
Id.global.f32 %f1, [%rd6];
add.s64 %rd7, %rd3, %rd5;
Id.global.f32 %f2, [%rd7];
add.f32 %f3, %f1, %f2;
st.global.f32 [%rd6], %f3;
ret;
```

```
#include <stdio.h>
```

```
mst.cu
#include <malloc.h>
extern "C" { __global__ void gStub(float* a, float* b){ } }
int main(){
  int N=2048;
  float* a=(float*)calloc(N, sizeof(float));
  float* b=(float*)calloc(N, sizeof(float));
  for(int i=0; i<N; i++){
     a[i]=2*i;
     b[i]=2*i+1;
```

```
float *a d, *b d;
  cudaMalloc((void**)&a d, N*sizeof(float));
  cudaMalloc((void**)&b d, N*sizeof(float));
  cudaMemcpy(a d, a, N*sizeof(float), cudaMemcpyHostToDevice);
  cudaMemcpy(b_d, b, N*sizeof(float), cudaMemcpyHostToDevice);
  gStub <<< N/128,128>>> (a d,b d);
  cudaDeviceSynchronize();
  cudaMemcpy(a, a d, N*sizeof(float), cudaMemcpyDeviceToHost);
  for(int i=0; i<N; i+=N/16)
    printf("%g\n",a[i]);
```

```
.version 8.5
.target sm_52
.address_size 64
    // .globl
               gStub
.visible .entry gStub(
    .param .u64 gStub_param_0,
    .param .u64 gStub_param_1
    ret;
```

```
tests/mystub> nvcc -dryrun -arch=sm_52 mst.cu -o mst
--keep 2> dryrun_mst.out
```

```
tests/mystub> 11
total 12
-rw-r--r-- 1 malkov users 5053 abr 21 15:18
dryrun_mst.out
-rw-r--r-- 1 malkov users 815 abr 21 15:09 mst.cu
```

```
tests/mystub> ls -ltr
total 4260
drwxr-xr-x 2 malkov users 21 авг 21 13:42 spare
-rw-r--r-- 1 malkov users 815 авг 21 15:09 mst.cu
                                                                 nvcc mst.cu -keep -o mst
-rw-r--r-- 1 malkov users 5053 авт 21 15:18 dryrun mst.out
-rw-r--r-- 1 malkov users 1091325 авг 21 15:21 mst.cpp4.ii
-rw-r--r-- 1 malkov users 24 авг 21 15:21 mst.module id
-rw-r--r-- 1 malkov users 1010983 авг 21 15:21 mst.cudafe1.cpp
-rw-r--r-- 1 malkov users 1184988 авг 21 15:21 mst.cpp1.ii
-rw-r--r-- 1 malkov users
                        13 авг 21 15:21 mst.cudafe1.c
-rw-r--r-- 1 malkov users 312 авг 21 15:21 mst.ptx
-rw-r--r-- 1 malkov users 1237 авг 21 15:21 mst.cudafe1.stub.c
-rw-r--r-- 1 malkov users 10401 авг 21 15:21 mst.cudafe1.gpu
-rw-r--r-- 1 malkov users
                          1960 авг 21 15:21 mst.sm 52.cubin
-rw-r--r 1 malkov users
                          6647 авг 21 15:21 mst.fatbin.c
-rw-r--r-- 1 malkov users
                          2248 abr 21 15:21 mst.fatbin
-rw-r--r-- 1 malkov users
                          8984 abr 21 15:21 mst.o
-rw-r--r-- 1 malkov users
                          872 abr 21 15:21 mst dlink.sm 52.cubin
-rw-r--r-- 1 malkov users 32 авг 21 15:21 mst dlink.reg.c
-rw-r--r-- 1 malkov users
                          3190 авг 21 15:21 mst_dlink.fatbin.c
-rw-r--r-- 1 malkov users 952 авг 21 15:21 mst_dlink.fatbin
-rw-r--r 1 malkov users
                          2904 авг 21 15:21 mst dlink.o
-rwxr-xr-x 1 malkov users 975856 авг 21 15:21 mst
```

```
tests/mystub> ./mst
0
256
512
768
1024
1280
1536
1792
2048
2304
..... •
```

```
extern "C"{
__global___ void gStub(float* a, float* b){
   int tid=threadIdx.x+blockIdx.x*blockDim.x;
   a[tid]=a[tid]+b[tid];
  }
}
```

```
.version 8.5
.target sm 52
.address size 64
      // .globl
                   gStub
.visible .entry gStub(
      .param .u64 gStub param 0,
      .param .u64 gStub param 1
      .reg .f32
                      %f<4>;
      .reg .b32
                   %r<5>;
      .reg .b64
                   %rd<8>;
```

```
ld.param.u64 %rd1, [gStub param 0];
ld.param.u64 %rd2, [gStub param 1];
cvta.to.global.u64 %rd3, %rd2;
cvta.to.global.u64 %rd4, %rd1;
mov.u32
              %r1, %tid.x;
mov.u32
            %r2, %ctaid.x;
mov.u32
            %r3, %ntid.x;
mad.lo.s32 %r4, %r2, %r3, %r1;
mul.wide.s32 %rd5, %r4, 4;
add.s64
          %rd6, %rd4, %rd5;
ld.global.f32 %f1, [%rd6];
add.s64
             %rd7, %rd3, %rd5;
ld.qlobal.f32 %f2, [%rd7];
add.f32
            %f3, %f1, %f2;
st.global.f32 [%rd6], %f3;
ret;
```

```
fatbinary --create="mst.fatbin" -64 --cicc-cmdline="-ftz=0 -prec_div=1 -prec_sqrt=1 -fmad=1 " "--image3=kind=elf,sm=52,file=mst.sm_52.cubin"  
"--image3=kind=ptx,sm=52,file=mst.ptx" --embedded-fatbin="mst.fatbin.c"
```

```
"/home/malkov/anaconda3/bin"/x86_64-conda-linux-gnu-c++
-D__CUDA_ARCH__=520 -D__CUDA_ARCH_LIST__=520
-D__NV_LEGACY_LAUNCH -c -x c++ -DCUDA_DOUBLE_MATH_FUNCTIONS
-Wno-psabi "-l/usr/local/cuda-12.5/bin/../targets/x86_64-linux/include" -m64
"mst.cudafe1.cpp" -o "mst.o"
```

```
nvlink -m64 --arch=sm_52 --register-link-binaries="mst_dlink.reg.c"
"-L/usr/local/cuda-12.5/bin/../targets/x86_64-linux/lib/stubs"
"-L/usr/local/cuda-12.5/bin/../targets/x86_64-linux/lib" -cpu-arch=X86_64 "mst.o"
-lcudadevrt -o "mst_dlink.sm_52.cubin" --host-ccbin
"/home/malkov/anaconda3/bin/x86 64-conda-linux-gnu-c++"
```

```
fatbinary --create="mst_dlink.fatbin" -64 --cicc-cmdline="-ftz=0 -prec_div=1
-prec_sqrt=1 -fmad=1 " -link "--image3=kind=elf,sm=52,file=mst dlink.sm 52.cubin"
--embedded-fatbin="mst dlink.fatbin.c"
"/home/malkov/anaconda3/bin"/x86 64-conda-linux-gnu-c++
-D CUDA ARCH LIST =520 -D NV LEGACY LAUNCH -c -x c++
-DFATBINFILE="\"mst dlink.fatbin.c\""
-DREGISTERLINKBINARYFILE="\"mst dlink.reg.c\"" -I.
-D NV EXTRA INITIALIZATION= -D NV EXTRA FINALIZATION=
-D CUDA INCLUDE COMPILER_INTERNAL_HEADERS__ -Wno-psabi
"-l/usr/local/cuda-12.5/bin/../targets/x86 64-linux/include"
-D CUDACC VER MAJOR =12-D CUDACC VER MINOR =5
-D CUDACC VER BUILD =82-D CUDA API VER MAJOR =12
-D__CUDA_API_VER_MINOR__=5 -D NVCC DIAG PRAGMA SUPPORT =1
```

-m64 "/usr/local/cuda-12.5/bin/crt/link.stub" -o "mst_dlink.o

```
"/home/malkov/anaconda3/bin"/x86_64-conda-linux-gnu-c++
-D__CUDA_ARCH_LIST__=520 -D__NV_LEGACY_LAUNCH -m64 -WI,--start-group
"mst_dlink.o" "mst.o" "-L/usr/local/cuda-12.5/bin/../targets/x86_64-linux/lib/stubs"
"-L/usr/local/cuda-12.5/bin/../targets/x86_64-linux/lib" -lcudadevrt -lcudart_static -lrt
-lpthread -ldl -WI,--end-group -o "mst"
```

tests/mystub> ./dryrun_mst.out

```
tests/mystub> ./mst
513
1025
1537
2049
2561
3073
3585
4097
4609
```